

Sesión Nº 1

Aprendizaje No Supervisado

(Traducido de presentaciones de Sriram Sankararaman y Junming Yin)

Plan de la unidad

- Introducción
 - Aprendizaje no supervisado
 - ¿Qué es el análisis de agrupamientos o clustering?
 - Aplicaciones de clustering
- Similaridades y Distancias entre datos
- Algoritmos de agrupamiento
 - K-means
 - Modelo de mezcla de normales (GMM)
 - Agrupamiento Jerárquico
- Mapas auto-organizados (redes de Kohonen)

Aprendizaje no supervisado


- Recordemos que en el contexto del aprendizaje **supervisado** (clasificación y regresión), los datos de entrenamiento se representan por $(x_i, y_i)_{i=1 \dots n}$ y el objetivo es “aprender” una función para **predecir y dado x**
- En el aprendizaje **no supervisado**, solo se tienen los datos $(x_i)_{i=1 \dots n}$, sin **etiquetas**. En este caso la idea es inferir algunas **propiedades de la distribución de X** .

¿Por qué aprendizaje no supervisado?

- Es más fácil contar con datos sin clasificar. **Etiquetar** datos puede ser costoso.
- Cuando los datos están en un espacio de **alta dimensionalidad**, este tipo de métodos permite encontrar **características** de los datos en espacios de **menor dimensión** que pueden ser suficientes para describir una muestra.
- En los primeros pasos de una investigación, es muy importante desarrollar un **análisis exploratorio de los datos**. De esta forma se obtiene una idea de la naturaleza y/o estructura de los mismos.
- El **análisis de agrupamientos (clustering)** o segmentación es un método de aprendizaje no supervisado

¿ Qué es el análisis de agrupamientos?

- El objetivo es descubrir grupos en los datos observados, tales que los datos dentro de un mismo grupo son mas **parecidos** que aquellos en los otros grupos.
- Se requiere:
 - Una función de **similaridad (distancia)** entre datos
 - Una función de **pérdida** para evaluar el agrupamiento efectuado
 - Un algoritmo para **optimizar** la función de pérdida



Plan de la unidad

- Introducción
 - Aprendizaje no supervisado
 - ¿Qué es el análisis de agrupamientos o clustering?
 - **Aplicaciones de clustering**
- Similaridades y Distancias entre datos
- Algoritmos de agrupamiento
 - K-means
 - Modelo de mezcla de normales (GMM)
 - Agrupamiento Jerárquico
- Mapas auto-organizados (redes de Kohonen)

Segmentación de imágenes



Resultados de una búsqueda de la palabra cluster

EisenLab

Commercial use of the ScanAnalyze, **Cluster** and/or TreeView executable and/or ... **Cluster** and TreeView are an integrated pair of programs for analyzing and ...

rana.lbl.gov/EisenSoftware.htm - 11k - [Cached](#) - [Similar pages](#)

[Book results for cluster](#)



 [The Linux Enterprise Cluster : build a highly ...](#) - by **Karl Kopper** - 466 pages

 [Messier's Nebulae and Star Clusters](#) - by Kenneth Glyn Jones - 456 pages

~~Searches related to: cluster~~

~~cluster headache~~

cluster analysis

server cluster

cluster sampling

[cluster windows 2003](#)

sql cluster

oracle cluster

clusty




cluster

Search

[Search within results](#) | [Language Tools](#) | [Search Tips](#) | [Dissatisfied? Help us improve](#) |

Clustering de datos de expresión de genes



Algoritmo de compresión de imágenes (Vector quantization)



Plan de la unidad

- Introducción
 - Aprendizaje no supervisado
 - ¿Qué es el análisis de agrupamientos o clustering?
 - Aplicaciones de clustering
- **Similaridades y Distancias entre datos**
- Algoritmos de agrupamiento
 - K-means
 - Modelo de mezcla de normales (GMM)
 - Agrupamiento Jerárquico
- Mapas auto-organizados (redes de Kohonen)

Distancias entre datos

¿Cómo medir la distancia o disimilaridad entre datos?

- Los resultados del agrupamiento depende de la elección de la distancia o medida de la disimilaridad.
- Usualmente depende del contexto de los datos en estudio.
- Depende de la naturaleza de las características observadas: Cuantitativas, ordinales, categóricas.

Disimilaridad en base a características


- Habitualmente los datos x_i contienen valores de ciertas **características** $x_{ij}, j = 1, \dots, p$.

- Una elección común de disimilaridad es la **distancia Euclidiana**


$$D(x_i, x_{i'}) = ||x_i - x_{i'}|| = \sqrt{\sum_{j=1}^p (x_{ij} - x_{i'j})^2}$$

- Los agrupamientos definidos a partir de la distancia Euclidiana son **invariantes** a **traslaciones y rotaciones** del espacio de características. No así al **escalamiento** de los datos.
- Una manera de **estandarizar** los datos es realizar una traslación y escalamiento de manera que todos tengan media 0 y varianza 1.

La estandarización no siempre es útil!!



Datos simulados, 2-means sin estandarización



Datos simulados, 2-means con estandarización

Plan de la unidad

- Introducción
 - Aprendizaje no supervisado
 - ¿Qué es el análisis de agrupamientos o clustering?
 - Aplicaciones de clustering
- Similaridades y Distancias entre datos
- Algoritmos de agrupamiento
 - **K-means**
 - Modelo de mezcla de normales (GMM)
 - Agrupamiento Jerárquico
- Mapas auto-organizados (redes de Kohonen)

K-means: Idea

- Representar el conjunto de datos en términos de K grupos, cada uno resumido por un **prototipo** μ_k
- Cada dato es asignado a uno de los K grupos
 - Representado por las responsabilidades $r_{ik} \in \{0, 1\}$
i
tal e: $\sum_{k=1}^K r_{ik} = 1$ para cada índice de datos
 - Ejemplo: 4 datos y 3 grupos: $(r_{ik}) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$

K-means: Idea

- Función de pérdida: La suma de los cuadrados de las distancias desde un dato hasta su prototipo **asignado**, conocido como la **dispersión dentro de los grupos**:

$$J = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|x_i - \mu_k\|^2$$

dato

Responsabilidad es

prototipos

Minimizando la función de pérdida

- Problema inicial:
 - Si los prototipos son conocidos se pueden asignar las responsabilidades.
 - Si se conocen las responsabilidades, se pueden calcular los prototipos óptimos.
- Se minimiza la función de pérdida con un algoritmo iterativo.
- Otra manera de minimizar la función de pérdida es mediante un enfoque de mezcla y separación.

Minimizando la función de pérdida

Paso E: Fija valores para μ_k y minimiza J con resp. a r_{ik}

- Asigna cada dato al prototipo **más cercano**

Paso M: Fija valores para r_{ik} y minimiza J con resp. a μ_k


- Esto resulta en:


$$\mu_k = \frac{\sum_i r_{ik} x_i}{\sum_i r_{ik}}$$


- Cada prototipo μ_k se define como la media de los puntos en el grupo.


La convergencia está garantizada ya que hay un número finito de definiciones de las responsabilidades.


Encuentra **mínimos locales**, por lo que se debiera correr el algoritmo con distintos valores iniciales.

























La función de pérdida después de cada paso E y M



¿Cómo escoger K ?

- En algunos casos es conocido a priori por la naturaleza del dominio del problema.
- Generalmente, es estimado a partir de los datos de acuerdo a una heurística específica.
- La función de pérdida J generalmente decrece cuando K crece.
- Idea: Asuma que K^* es el número correcto
 - Se asume que para $K < K^*$ cada grupo estimado contiene un subconjunto de los verdaderos grupos subyacentes.
 - Para $K > K^*$ algunos grupos naturales están separados
 - Así, se asume que para $K < K^*$ la función de costo decrece sustancialmente, mientras que posteriormente el decrecimiento no es significativo.

¿Cómo escoger K ?



- A partir de $K=2$ el decrecimiento disminuye sustancialmente, por lo que este es el valor escogido.

Inicializando K-means

- K-means converge a un óptimo local
- Los grupos definidos dependen de los valores iniciales
- Algunas heurísticas
 - Escoger aleatoriamente K datos como prototipos.
 - Estrategia voraz (greedy). Escoger el prototipo $i + 1$ tal que esté lo mas alejado posible de los prototipos $\{1, \dots, i\}$

Limitaciones de K-means

- Asignación determinista de los datos a cada grupo.
 - Pequeñas variaciones en los datos pueden significar un cambio de grupo
 - Solución: reemplazar asignación determinista por asignación de probabilidades (GMM)
- Asume grupos esféricos y cada grupo con la misma probabilidad.
 - Solución: GMM
- Grupos arbitrarios con diferentes valores de K
 - A medida que K crece, la pertenencia a los grupos cambia de manera arbitraria, los grupos no están siempre anidados
 - Solución: Agrupamiento jerárquico
- Sensibilidad a los outliers
 - Solución: uso de otras funciones de pérdida.

Referencias

- Hastie, Tibshirani and Friedman, The Elements of Statistical Learning, Capítulo 14
- Bishop, Pattern Recognition and Machine Learning, Capítulo 9